



Análise Epidemiológica de Dengue

Rio de Janeiro (2010-2016) — Topological Data Analysis

Análise Epidemiológica

Projeto de Ciência de Dados

Novembro 2025

- 1 Introdução
- 2 Semanas Epidemiológicas
- 3 Normalização
- 4 Matrizes de Distância
- 5 Complexos Simpliciais
- 6 Análise de Componentes Principais
- 7 Clusterização
- 8 KeplerMapper
- 9 Conclusões

Objetivos Principais

- ① **Análise Temporal:** Padrões de semanas epidemiológicas
- ② **Normalização:** Comparação ajustada por população
- ③ **Distâncias:** Identificar dinâmicas sincronizadas (L1/L2)
- ④ **Complexos Simpliciais:** Estrutura topológica
- ⑤ **Clusterização:** Agrupamento de municípios

Técnica Principal

Topological Data Analysis (TDA)

Revelando estruturas ocultas nos dados epidemiológicos através de complexos simpliciais e análise de forma.

Fonte dos Dados

Características do Dataset

- **Arquivo:** Dengue_Brasil_2010-2016_RJ.xlsx
- **Período:** 2010 a 2016 (7 anos)
- **Região:** Estado do Rio de Janeiro
- **Granularidade:** Casos por município e semana epidemiológica
- **Municípios:** 91 municípios analisados

Ano de Referência: 2013

Selecionado por apresentar:

- Maior número de casos no período
- Dados completos (52 semanas)
- Dinâmica epidêmica bem definida

Semanas Epidemiológicas

Definição

A **semana epidemiológica (SE)** é a unidade de tempo padrão da OMS/CDC para vigilância epidemiológica.


- Maioria dos anos: **52 semanas**
- Anos especiais: **53 semanas** (ex: 2014)
- SE 1 inicia no primeiro domingo \geq 1º janeiro

Ano	Semanas
2010	52
2011	52
2012	52
2013	52
2014	53
2015	52
2016	32*

Tabela: *Dados incompletos

Observações do Período Epidêmico

- **Picos epidêmicos:** Semanas 1–17 (janeiro a abril)
- **Padrão consistente:** Aumento no verão, queda no inverno
- **Maior surto:** 2013
- Correlação com período de chuvas e temperaturas elevadas



Métodos de Normalização

Normalização 1: Taxa de Incidência

Casos ajustados pela população (Censo 2010):

$$\text{Taxa} = \frac{\text{Casos}}{\text{População}} \times 100.000$$

Objetivo: Comparar intensidade da epidemia entre municípios de diferentes tamanhos.

Normalização 2: Área Unitária

Série temporal normalizada para soma = 1:

$$\tilde{x}_i = \frac{x_i}{\sum_j x_j}$$

Objetivo: Comparar a *forma* das curvas epidêmicas, independente da magnitude.

Importância

A normalização por área unitária permite identificar municípios com **dinâmicas sincronizadas**, mesmo com números absolutos muito diferentes.

Taxa de Incidência — Resultados

Por Taxa (100.000 hab.)

Municípios com maior risco relativo:

- ① Municípios pequenos
- ② Alta densidade vetorial
- ③ Infraestrutura precária

Por Casos Absolutos

Municípios com maior carga:

- ① Rio de Janeiro (capital)
- ② Niterói
- ③ Grandes centros urbanos

Insight

Municípios pequenos podem ter taxas altíssimas com poucos casos absolutos — importante para políticas de saúde pública diferenciadas.

Distâncias L1 e L2

Para identificar municípios com dinâmicas **sincronizadas**, calculamos distâncias entre curvas normalizadas:

Distância L1 (Manhattan)

$$d_{L1}(x, y) = \sum_{i=1}^{52} |x_i - y_i|$$

- Mais **robusta** a outliers
- Soma das diferenças absolutas
- Interpretação: “quanto difere em total”

Distância L2 (Euclidiana)

$$d_{L2}(x, y) = \sqrt{\sum_{i=1}^{52} (x_i - y_i)^2}$$

- **Penaliza** grandes diferenças
- Sensível a picos isolados
- Interpretação: “distância geométrica”

Matrizes de Distância — Estatísticas

Estatística	L1 (Manhattan)	L2 (Euclidiana)
Dimensões	91×91	91×91
Mínima (não-zero)	≈ 0.20	≈ 0.05
Máxima	≈ 1.88	≈ 0.80
Média	≈ 0.75	≈ 0.22

Tabela: Resumo das matrizes de distância (ano 2013)

Interpretação

- **Distância pequena** → curvas epidêmicas similares
- **Distância grande** → dinâmicas diferentes
- Matrizes simétricas: $d(A, B) = d(B, A)$

Pares Mais Sincronizados

Top Municípios com Dinâmicas Similares (L1)

Municípios conectados pela epidemia:

- Região metropolitana do Rio
- Municípios vizinhos geograficamente
- Padrões de mobilidade populacional

Aplicação

Identificar pares sincronizados permite:

- Ações coordenadas de controle vetorial
- Compartilhamento de recursos
- Modelos de propagação espacial

Topological Data Analysis (TDA)

O que é um Complexo Simplicial?

Estrutura topológica que generaliza grafos, revelando conexões de ordem superior:

Dim.	Nome	Descrição
0	Vértice	Um ponto (município)
1	Aresta	Conexão entre 2 municípios
2	Triângulo	Trio completamente conectado
3	Tetraedro	Quatro municípios conectados



0-simplex



1-simplex



2-simplex



3-simplex

Construção do Complexo

Método

Dois municípios são **conectados** se sua distância é menor que um **limiar** ε :

$$\text{Aresta}(A, B) \iff d(A, B) < \varepsilon$$

ε pequeno

- Poucos vértices conectados
- Revela **núcleos** mais sincronizados
- Estrutura esparsa

ε grande

- Muitas conexões
- Complexo mais **denso**
- Pode perder informação local

Estratégia: Testar múltiplos limiares (percentis 10%, 20%, ..., 90% da distribuição de distâncias).

Resultados — Complexo Simplicial

Estruturas Identificadas

Ao variar o limiar ε , identificamos:

- **Componentes conexas:** Grupos de municípios sincronizados
- **Triângulos:** Trios com dinâmicas fortemente correlacionadas
- **Clusters topológicos:** Agrupamentos naturais da epidemia

Interpretação Epidemiológica

- Triângulos indicam **corredores de transmissão**
- Componentes isoladas sugerem **dinâmicas independentes**
- Evolução do complexo com ε revela **hierarquia de similaridade**

Principal Component Analysis

Técnica que identifica as **direções de maior variância** nos dados:

$$Z = X \cdot W$$

onde W contém os autovetores da matriz de covariância.

Aplicação

- Reduzir 52 dimensões (semanas) para 2-3
- Visualizar municípios em espaço 2D
- Identificar padrões principais

Variância Explicada

- PC1: ~30-40% da variância
- PC1 + PC2: ~50-60%
- 5 componentes: >80%

Interpretação dos Componentes

Componentes Principais

- PC1 Intensidade geral da epidemia (pico vs. vale)
- PC2 Timing do pico (início vs. fim do período)
- PC3 Forma da curva (unimodal vs. bimodal)

Projeção 2D

No espaço PC1 × PC2:

- Municípios **próximos** → curvas similares
- **Clusters visuais** emergem naturalmente
- Outliers identificados facilmente

Métodos de Clusterização

K-Means

- Particiona em k grupos
- Minimiza variância intra-cluster
- Requer definir k

DBSCAN

- Baseado em densidade
- Detecta outliers
- Formas arbitrárias

Hierárquico

- Dendrograma
- Múltiplas resoluções
- Interpretável

Métricas de Validação

- **Silhouette Score:** Coesão vs. separação (-1 a 1)
- **Calinski-Harabasz:** Razão de variâncias (maior = melhor)

Resultados — Clusters Epidêmicos

Perfis Identificados

Os clusters revelam diferentes **padrões epidêmicos**:

Cluster 0 Pico precoce (semanas 5-10), alta intensidade

Cluster 1 Pico tardio (semanas 12-17), moderado

Cluster 2 Baixa intensidade, curva achatada

Cluster 3 Padrão bimodal (dois picos)

Implicações

- Municípios no mesmo cluster requerem **timing similar** de intervenções
- Recursos podem ser **compartilhados** entre municípios do mesmo cluster
- Modelos preditivos específicos por cluster

O que é?

Implementação Python do algoritmo **Mapper** para TDA, gerando visualizações HTML interativas.

Arquivos Gerados

- kmapper_pca_2013.html
- kmapper_tsne_2013.html
- kmapper_l2norm_2013.html
- kmapper_distancia_2013.html

Funcionalidades

- Zoom e pan interativos
- Hover para ver municípios
- Cores por atributo
- Exportável



Abra os arquivos HTML no navegador para explorar!

Principais Achados

Resultados

- ① 2013 foi o ano com maior surto epidêmico
- ② Padrão sazonal consistente: picos em janeiro-abril
- ③ Grupos de municípios com dinâmicas sincronizadas identificados
- ④ Complexos simpliciais revelam estrutura topológica da epidemia
- ⑤ Clusters com perfis epidêmicos distintos

Contribuição Metodológica

Demonstração do uso de **Topological Data Analysis** para análise epidemiológica, indo além de métodos estatísticos tradicionais.

Para Saúde Pública

- Ações coordenadas entre municípios sincronizados
- Intensificar controle vetorial pré-verão
- Alocar recursos por cluster epidêmico

Trabalhos Futuros

- Incluir dados climáticos
- Análise de persistência
- Modelos preditivos por cluster
- Comparação com outros estados

Estrutura do Projeto

Módulos Python

`tarefa0_carregar_dados.py` Carregamento e preparação dos dados

`tarefa1_semanas_epidemiologicas.py` Calendário epidemiológico

`tarefa2_normalizacao.py` Normalização por população e área

`tarefa3_distancias.py` Cálculo de distâncias L1/L2

`tarefa4_complexo_simplicial.py` Construção de complexos

`tarefa5_kmapper.py` Visualizações KeplerMapper

Repositório



<https://github.com/mei-the-dev/dengue>

Obrigado!

🌟 Análise Epidemiológica de Dengue

✉️ Dúvidas e sugestões são bem-vindas

🌐 <https://github.com/mei-the-dev/dengue>